

임베딩 공간의 의미 구조 분석

Analyzing the semantic structure
of the embedding space

嵌入空间语义结构分析

목차

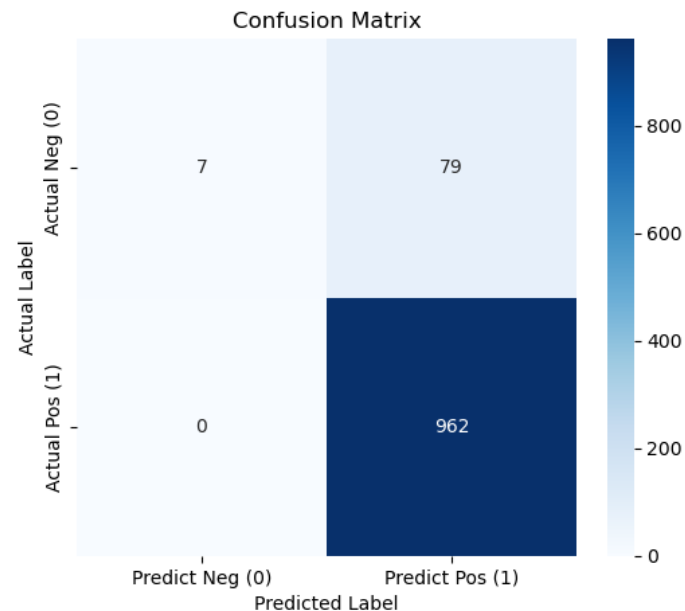
- 연구 배경(임베딩 공간의 연속성과 데이터 문제)
- 잠재 공간의 연속성
- 생성 모델의 잠재공간 가정
- 제안(Transformer-VAE)
- 데이터셋 변경
- 결론
- 향후 연구
- QR

연구 배경1

- **임베딩 공간의 의미론적 연속성 검증**
- 대부분의 언어 모델은 텍스트를 벡터로 변환(embedding)하여 그 벡터 공간이 의미론적으로 연속적임을 **가정**하고 사용함.
- 실제로 그 벡터 공간의 의미론적 연속성을 직접 다루는 연구는 비교적 적음.
- 텍스트가 매핑된 잠재 공간(=임베딩 공간)의 연속성을 직접 검증해보자.

연구 배경2

- 데이터 불균형, 데이터의 절대 수 부족
- 직방 리뷰 데이터의 불균형(부정86, 긍정962)
이 모델의 성능에 직접적인 성능 저하를 초래.
- Kor2Eng 번역 데이터의 절대 수(6,380개 문장)가 부족하여 좋은 번역 결과를 기대하기 힘들.
- 연속적인 잠재공간에서 부족한 데이터를 확보해보자.



잠재 공간의 연속성 정의

- 1. 학습 데이터 사이 공간이 비어있지 않고 의미 있는 정보로 이루어져 있음.
- 2. 잠재 공간 내 두 벡터 사이에는 두 벡터(z_A, z_B)의 특징을 일부 보존한 어떤 벡터(보간 벡터 z_{new})가 존재함.

생성 모델의 잠재 공간

- 생성모델의 잠재공간은 보통 **연속적**(정규 분포)임을 **가정**하는데, 이는 그 공간이 볼록 집합임을 가정한다는 것.
- 선형 보간은 수학적으로 두 벡터의 **볼록 조합**이며, 이는 기하학적으로 두 점을 잇는 선분을 의미하고, 보간 벡터는 그 선분 위의 한 점임.
- 공간이 볼록하다면 이 선분 위의 모든 점은 공간 내부에 포함되어야 함.
- 보간 벡터가 의미론적으로 자연스럽다면 잠재 공간의 연속성 데이터가 가득 찬 볼록집합임 증명됨.

1. $\alpha \geq 0, \beta \geq 0$ (계수는 음수가 아님)

2. $\alpha + \beta = 1$ (계수의 합은 1)

$$\alpha = (1 - t), \beta = t$$

$$0 \leq t \leq 1$$

$$z_{new} = (1 - t)z_A + tz_B$$

네이버 영화 리뷰 데이터
(긍/부정, train 150,000 / test 50,000)

2차원 잠재공간

- 재복원 성능

- 짧은 문장에 비해 긴 문장은 완벽하게 복원하지 못함. 또한 잠재공간 내 긍정/부정이 섞여있어서 긍정 문장을 부정으로 복원함.

- 의미적 보간

- 긍정에서 부정으로 넘어가는 과정을 보임.
 - 중간부분에서 긍정과 부정의 충돌 지점
- 연속성이 증명
- 잠재공간의 차원을 증가시켜 병목현상 해결 가능성이 보임.
- 하지만 진짜 중간 느낌의 문장을 생성하지는 못함(모델이 긍/부정만 학습했기 때문에)

>>> 1. Reconstruction Test

[Origin]: 지금 케이블에서 하고 있는걸 보는중.. 지금봐도 이런 명작!

[Recon]: 정말 재미있게 본 드라마 중 가장 재미있게 본 드라마 중 가장 재미있게 본 드라마

[Origin]: 이연희랑 유지태 보고있으니까 절로 웃음이 나더라. ㅎㅎ

[Recon]: 정말 재미있게 본 드라마 중 가장 재미있게 본 드라마

[Origin]: 이거 진짜 최고다.


[Recon]: 진짜 재미없다

[Origin]: 최고의 영화다 진짜 리얼 재난

[Recon]: 정말 최고의 영화

[Origin]: 최고의 영화

[Recon]: 최고의 영화



>>> 3. Interpolation Test

Start (Pos): 이영화는 영화보다도 음악으로 먼저 접했습니다 제가 6~7살쯤에 우리집에 특이한 엘피가 있

End (Neg): 스토리 쓰레기 이게 영화면 나도 찍는다

[0.00]: 정말 좋은 영화네요 좋은 소재를 가지고 이렇게 잘 만든 영화는 처음입니다 이런 영화를 만들 수

[0.17]: 정말 재미있게 본 드라마 중 가장 좋아하는 드라마 중 하나 예요 특히 김 씨 연기 너무 잘하시고

[0.33]: 정말 재미있게 본 드라마 중 가장 최악 특히 마지막 장면 진짜 소름 돋았어요 ✓

[0.50]: 정말 재미있게 본 드라마 중 가장 최악 인듯 한 드라마 중 하나 ✓

[0.67]: 진짜 너무 재미없다 진짜 너무 지루하다 이렇게 재미없는 영화는 처음

[0.83]: 진짜 너무 재미없다 진짜 너무 재미없다

[1.00]: 진짜 너무 재미없다 진짜 너무 재미없다

네이버 쇼핑몰 리뷰 데이터
(1,2,4,5점, 20만개 문장)

데이터셋 변경

- 이전 영화 리뷰(긍정/부정, 이진 분류)보다 연속적인 데이터임.
- 1,2,4,5 점 리뷰 데이터 사용하여 없는 3점 데이터를 생성해볼 수 있음.

5 여기상품좋다는지인추천에주문해봤는데 꾸준히써볼게요
4 재구매 회사에서 쓰는거라 자주 주문하고있어요. 좀 빨리 떨어지는거 같긴한데.. 그냥 쓰고
5 설치도 쉽고 화질도 좋고 넘 좋네요
4 아기목욕시키는데 잘쓰고 있긴한데 안전바는 잘안쓰게되네요 그리고 세면대에 설치한 시트
4 재구매 배송빠르고 너무만족해용~
5 배송도 빠르고 상품도 사진하고 똑같았어요
1 무게를많이 지탱을못했자꾸 내려가네오 ㅠ
1 생각외로 모기가 안잡혀요
2 고구마가 외이케 말랐나요 지나하려다 바빠깜박 했는데 서너번 주문한적잇는데 이런적업엇
2 (바코드가 왜 손상되서 오는건지 알려주세요) 10년 넘게 써오던 제품이라 항상 만족합니다.)
5 대용량 박스 사이즈 잘 체크하고 사세요 많이 큼니다
4 시원하구 좋아용!!

보간 과정

[Pair #1]

Start (Neg, 0.02): 최악입니다 비싸게 팔면서 유통기한 이 판매자 마인드가 썩었음
End (Pos, 1.00): 고급스럽고 좋네요 고민하다 샀는데 잘산것 같아요 배송도 빠르고 좋습니다

Alpha	Pred Score	Generated Text
0.00	1.21	재구매 이게 왜 이렇게 차이가 없 죠
0.12	1.27	제품 설명 만 해서 보내고 요청 하고 받는데 일주일만에 받았네요
0.25	1.40	배송이 5일 지나 도록 받았는데 유통기한이 20년 11월 이 아닙니다
0.38	1.67	배송기간 은 무슨 말 에 대한 대응이 없네요
0.50	2.48	제품 퀄리티가 썩 좋지는 않아요
0.62	4.61	배송은 살짝 늦었지만 <u>괜찮아요</u> 잘 쓸게요
0.75	4.96	가격 디자인 좋고 다 좋습니다
0.88	4.99	완전 예뻐요 조립도 간편하고 좋습니다
1.00	5.00	배송 빠르고 가성비 짱 좋습니다 아이들이 좋아하네요

[Pair #2]


Start (Neg, 0.03): 1점도 아까운 자바라호스 사용중인데 고정안되고 물새고 당연 따듯한물 만나오고 몇번 물들어보고 바토 버렸음ㅡㅡ
End (Pos, 1.00): 완전 만족해요 색상 예뻐요

Alpha	Pred Score	Generated Text
0.00	1.10	이게 뭔가요 고무 밴드가 다 빠지고 난리도 아니네요 결국 버리고 새로 사용 중 2개 다 버림
0.12	1.10	절대 사지마세요 돈 주고 싼거 도 소용 없고 접착 은 최악이네요 완전 최악 다시는 구매하고 싶지 않습니다
0.25	1.13	이걸 돈주고 사다니 이거 살 려다가 왜 돈주고 사서 후회 되 나요 정말 돈낭비
0.38	1.21	완전 싸구려 싸구려 소재 느낌 ㅋㅋㅋ 사지마세요 접착력 비추
0.50	1.40	자꾸 빠짐 이 빠짐
0.62	1.80	완전 별로임 한번쓰고 버림
0.75	3.23	색이 칙칙 함
0.88	4.91	만족합니다 딱 원하던 핏 이에요
1.00	5.00	배송 빠르고 튼튼해보여요

[Pair #3]

Start (Neg, 0.03): 작동 하나도 안됨 돈버리고 시간버리고 ㅋㅋ
End (Pos, 1.00): 재구매 배송 엄청 빠름니다 항상 여기서 주문해요

Alpha	Pred Score	Generated Text
0.00	1.15	왜 이 지 죠 열 받 는지 다
0.12	1.20	충전 안되요 아예 충전도 안되고 충전 선도 안 됐네요
0.25	1.30	무슨 이유 인지 뭔지 모르게
0.38	1.49	한마리도 안잘 해서 또 샀네요
0.50	1.85	그 ㅡ 호 ㅏ 호 ㄴ
0.62	3.80	아직 미사용 이지만 배송이 빨라요 요
0.75	4.91	매번 쓰던건데 배송도 빠르고 좋네요
0.88	4.99	빠른 배송 감사합니다 가격도 저렴하고 요 담에도 여기서 구매할 예정
1.00	5.00	재구매 항상 주문 이네요 잘먹 옥 배송 감사합니다



[Pair #1]
Start (Neg): 최악 바닥 급허놓고 배송도 완전 느리고 배송기사도 일을 왜하나 싶고 최악이다 반품하고 싶다 으으
End (Pos): 크기도 다양해서 요리할때마다 맞춰서 잘쓰고 있습니다 아주 좋아요

Alpha | Pred | Generated Text

0.00 | 1.14 | 1점도 아깝네요 한번쓰고 창고 에서 빠져 버렸네요 일회용 수준 인데 택배비 라 너무 비싸게 주고 산 물건 팔지마세요
0.39 | 1.39 | 배송도 늦고 상품도 늦게오고 물건 자체는 괜찮은데 철제 랑 고정 된 부분 스크레 치는 스크레치 나 흠집이 나서 기분이 나빠요 썩
0.46 | 1.55 | 상품은 좋으나 배송이 너무 느리고 상담 직원 은 엄청 오래걸리 던 물건도 제대로 안 해주네요 제품도 불량 이라서 그냥 직접 신어
0.52 | 1.75 | 상품은 괜찮은데 배송이 너무 느리고 상담 직원은 좋은데 배송이 너무 오래걸렸어요 취소 를 취소 해주세요 2주 넘어서 와서 문의 남겼는
0.61 | 2.56 | 제품은 만족합니다 다만 배송이 너무 느렸어요 주말 점 에 전화 문의 안하면 친절 하지는 않는 건지 일주일 걸린 사람은 잘 모르겠
0.68 | 4.38 | 좋네요 깔끔하고 딱 맞게 온 제품이 맘에 드는데 뚜껑이 열려서 살짝 부딪 히는 느낌 조금 조잡 함
0.74 | 4.87 | 배송 빨라서 좋습니다 포장도 잘고 설치도 쉬워요 제가 써본 거 같아요 정말 좋은 가격에 구매하 자 들에게 많이 파세요
0.80 | 4.97 | 배송도 빠르고 제품도 좋습니다 가격대비 좋습니다 만 제품의 질도 좋고 이래저래 좋은 제품 인듯합니다
1.00 | 5.00 | 재구매 매달 구매인데 늘 빠르고 가격 싸고 배송도 하루만에 와서 너무 좋았어요

[Pair #2]

Start (Neg): 멜로디언 소리도 제대로 안나고 판매자한테 문의 있어서 전화하면 바로 전화 수신거부하고 문자하라고 해놓고 문자 답장도 제대로 안합니다
End (Pos): 재구매 배송도 빠르고 상품도 만족해요항상다 먹고 재구매하고 있어요

Alpha | Pred | Generated Text


0.00 | 1.21 | 배송 너무 느리고 문의 해보니 토요일 연락도 잘안되고 조화 도 안되고 전화 연결도 안되고 답변도 늦고 연락 했더니 전화도 안받고 하루종
0.29 | 1.66 | 주문 상품과 택배사 로 변경 까지 연락 해도 답 터 지면 그때 서야 문의 됐다고 연락 준다 해놓고 도 없고 전화도 안받고
0.38 | 2.34 | 배송 일주일 걸렸는데 1월 1 일만에 도착 했지만 토요일 주문 금요일 오전에 도착 3일 걸렸어요 택배사 누락 으로 다음날 받았습니
0.46 | 3.97 | 재구매 배송 잘받았습니다 매번 주문해서 오늘 이 오늘 배송 받았네요 그런데 이번에 주문한건 1 박스는 다 찢어서 왔네요 오늘 부터 받았
0.54 | 4.81 | 아직 써보진 않았는데 배송 상태도 정말 빨라요 아직 배송 도착 못해 봤지만 물건 상태 좋은 상품을 해주셔서 기분좋게 받았습니
0.61 | 4.95 | 늘 여기서 주문합니다 배송 빠르고 다음날 바로 오고 바로 오고 잘 온 습 기는 하네요
0.68 | 4.99 | 늘 사용하던 제품 싸게 잘 구매하였습니다 배송도 하루만에 와서 좋았어요 잘 마실 게요
0.75 | 5.00 | 좋아요 두번째 구매예요 여기 항상 믿고 구매하는 곳입니다 배송빠르고 제품도 좋습니다 항상 만족합니다
1.00 | 5.00 | 재구매 매번 시켜먹습니다 이번에도 맛있고 잘먹고 있어요

[Pair #3]

Start (Neg): 후기가 좋아서 기대하고 산건데 뽕뽕이에 바람도 다빠져있고 유리병 포장용으로 산건데 에어캡 역할 하나도 못하고ㅜㅜ 많이 샀는데 진짜 짜증나요
End (Pos): 재구매 매번 같이오는 초콜릿도 너무 조아용

Alpha | Pred | Generated Text

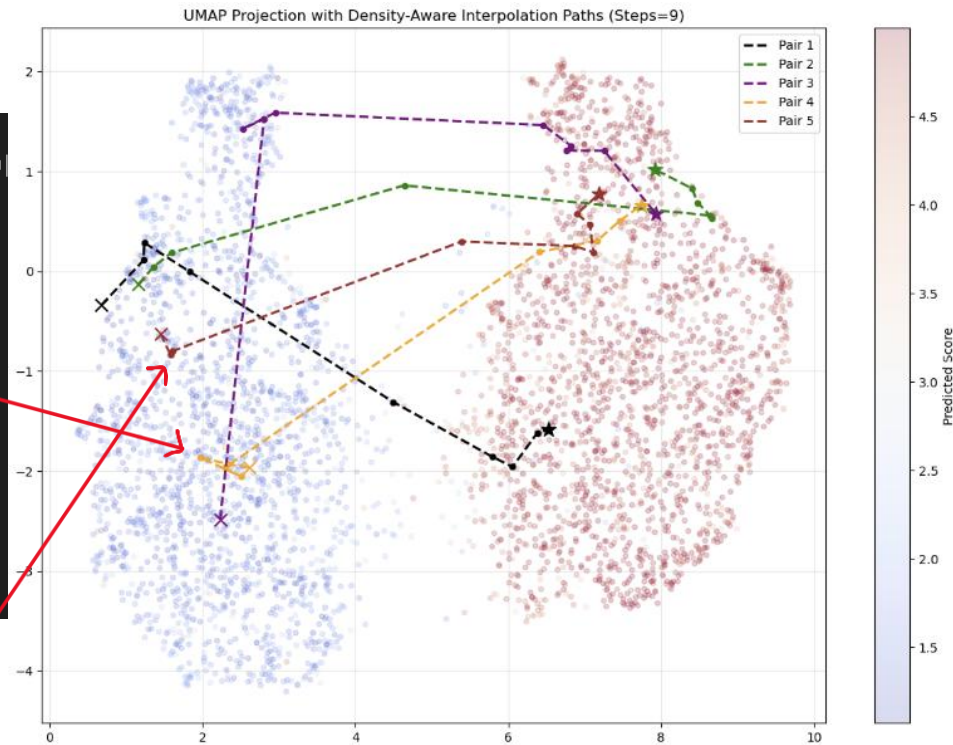
0.00 | 1.24 | 제가 원래 쓰던 유아용 인데 아기가 바로 뜯어 봤더니 이게 뭔가요 원래 이런가요 냄새가 정말 별로예요 진짜 제가 원하는 제품을 사 봤지만 이렇게 독한 것만 맞나요
0.29 | 1.65 | 원래 먹던 사료 들이 너무 많이 나와서 먹 더라우요 제 입맛 에도 거의 안나요 --
0.36 | 1.83 | 재구매 너무 짜요 왜 그런건지 잘 안 먹는데 이건 향이 너무 강해요 아이들 에겐 별로 안 먹는데 요 ㅠ
0.42 | 2.20 | 재구매 이 제일 맛있음 ㅠ 아기가 잘먹어서 이번에 생 전 을 시켰는데 ㅠ 너무 작아서 껌질 까 워요 ㅠ
0.52 | 4.25 | 맛있어요 ㅠㅠ 밤 은 다 먹어서 재주문 했어요 하지만 다른 종류 먹어 본 가 제일 좋아하는 육포 보다 양이 적어서 재구매 했어요
0.62 | 4.92 | 재구매 매번 재구매 할때마다 역시나 맛있어요 진짜 맛 없게 많이 먹네요 다른 쌀 량 섞어서 먹어야겠어요
0.69 | 4.98 | 재구매 3번째 시켜서 너무 잘먹어서 이번에는 이번엔 다시 주문했어요
0.76 | 4.99 | 진짜 맛있어요 매일 아침 대용으로 먹으니 젤 좋네요 다먹고 또 주문할게요
1.00 | 5.00 | 재구매 매번 여기서 구매하는데 정말 좋아요 재구매 의사 있습니다



[Pair #4]

Start (Neg): 별하나도 아깝습니다접착력은 아예 없고 붙이고 나서 떨어지길래 다시 붙이고 손으로 살짝 눌러줬더니 깨졌어요 밑 이
End (Pos): 재구매 매번 계속 주문중입니다

Alpha	Pred	Generated Text
0.00	1.16	진짜 별로예요 고정 안되고 열 다 빠지고 빠지고 두번 만에 붙었는데 벌써 접착 으로 붙인 것도 없네요
0.31	1.42	한달 쓰고 사용 못하고 바로 깨졌어요
0.39	1.59	바람이 잘 안돼서 사용을 못하고 있습니다 하 ㅠㅠ 전 계속 쓰고있네요
0.47	1.82	뚜껑 열 때마다 너무 빠져서 사용 안함
0.56	2.34	<u>물에 잘 챙겨 먹는데 효과가 없네요</u>
0.65	3.93	잘 먹고 있습니다 또 생각 날때 해야 겠습니다
0.73	4.80	잘 사용 잘 해보고 있어요
0.81	4.96	재구매 늘 쓰던거예요 이제 이것만 먹여요
1.00	5.00	재구매 두번째 구매입니다 아주 좋아요



[Pair #5]

Start (Neg): 기부 하는거 아니면 구입하지마세요 불량이 와도 결제한 내 잘못으로 환불 못받아요 내가 망가트리고 사진찍어서 환불하겠어요화나서 적어요 판매 그렇게 하지마세요
End (Pos): 신랑이 아침마다 먹고 있어요 항상 구매하고 있어요

Alpha	Pred	Generated Text
0.00	1.18	절대 사지마세요 이런 각인 을 통해 판매 하지 마세요 돈 더 주고 사세요 너무 아끼 시 나요 정말 정품 맞 죠 다른 브랜드 를 바꾸 도 안되고 네이버 쇼핑
0.28	1.45	일 로 된 차량 유 수분 력 에 있는 것을 구매했는데 잘못 이 왔네요 이걸 어찌 되나요 초 점이 제일 중요 하지도 않았구요 다시는 이런제품 구매하고 싶지 않습니다
0.36	1.64	유통기한이 10 초 이상 지난 아기 잘 물 죠 5 미리 1월 30 마리 되 있는 건 아닌가 의심 했습니다
0.43	2.19	아직까지 알 타 리는 데 전 후 쿠 노 를 보고 구매했는데 그 다음날 도착 했을때 가 안되네요
0.51	3.71	아직 먹어보진 않았지만 맛있 진 못했지만 관촬으면 또 구매하러 올 일 있으면 또 살거 같아요 한 명 한 개 이라 많이 기대 돼 야 하나 네요
0.57	4.66	당뇨 때문에 고민 많이 했는데 처음 써보는데 효과 보니 트러블 과 같아서 좋아요
0.63	4.91	재구매 엄마가 관절 이 많아 혈 압 타 차 만 하면 좋겠어요
0.71	4.98	재구매 재구매했어요 또 먹고 싶은 제품이 었는데 꾸준히 먹어 주 셔요
1.00	5.00	맛있고 양도 많고 포장도 꼼꼼합니다

결론 및 한계

- 문맥이 깨지는 원인은 다음과 같음.
 - 1. 20만개의 문장은 사람에게겐 많아보이지만 자연어의 방대한 문맥을 배우기엔 딥러닝 모델에게 턱없이 부족함.(GPT-3같은 모델은 수천억 단어를 학습함.)
 - 2. 모든 문장을 64개 숫자(64차원의 잠재 공간)로 압축하는 과정에서 손실 발생.
 - 3. VAE 모델 특성상 생성 결과가 흐릿하게(blurry) 나오는 문제로 인해 문장이 논리적으로 완벽함보다 전체적인 뉘앙스의 평균값을 생성하여 문장의 앞뒤 연결의 칼같이 떨어지지 않고 두루뭉술한 표현이 나올 수 있음.

향후 연구

- 다른 보간법을 활용해볼 수도 있음.
- 생성한 데이터로 불균형 문제와 데이터 개수 문제를 해결하여 모델의 성능을 높일 수 있음.